

MASTERSEMINAR · PITCH · SS 2026

Optimierung von Transferfunktionen im Volume Rendering mit Reinforcement Learning

Kevin Kunkel

Universität Leipzig · Betreuer: Prof. Gerik Scheuermann, Dr. Thomas Wischgoll, Dr. Baldwin Nsonga



UNIVERSITÄT
LEIPZIG

- | | |
|---|--------|
| 1 — Motivation: Warum Transferfunktions-Design so mühsam ist | 2 Min. |
| 2 — Verwandte Arbeiten & Fragestellung | 2 Min. |
| 3 — Architektur: Sprache/Text → Kommando → Render → Bewertung | 3 Min. |
| 4 — Die Transferfunktion: 24 Werte, echte Hounsfield-Einheiten | 2 Min. |
| 5 — Der Prototyp: Live-Demo der Chat-Oberfläche | 2 Min. |
| 6 — Kommandogrammatik & Parser-Auswertung | 2 Min. |
| 7 — Ergebnisse an echten CT-Daten | 1 Min. |
| 8 — Erkenntnisse aus dem Testen | 1 Min. |
| 9 — Von der Baseline zum RL-Agenten: SAC, Online-Lernen, RLHF | 4 Min. |

Direct Volume Rendering: volumetrische Daten (CT, MRT, Simulationen) sichtbar über eine **Transferfunktion**.

Definition: Transferfunktion $T : [\min, \max] \rightarrow [0, 1]^4$ — jeder Skalarwert bekommt Farbe (RGB) und Opazität (α). Die Wahl von T entscheidet, welche Strukturen sichtbar werden.

Das Problem:

- Parameterraum groß, unintuitiv
- Erfordert Domänenwissen (z. B. Hounsfield-Einheiten)
- Manuelles Nachjustieren kostet Zeit

Der Wunsch:

- “Zeig mir nur den Knochen”
- “Weichgewebe ist zu dominant”
- Sprache/Text statt Schieberegler


TF-Design: sprachbasiert & nicht

- T2TF: Text $\rightarrow$ TF, differenzierbar (Jeong et al., 2024)
- IntuiTF: MLLM als Explorer **und** Bewerter (Wang et al., 2025)
- NLI4VolVis: Chat-Agenten für Volume-Viz (Ai et al., 2025a)
- Segmentierung via Vision-Transformer (Engel et al., 2024)
- TF-Optimierung über Bildvergleich (Neuhäuser & Westermann, 2023)


RL & Evaluation für Parameterexploration

- Deep RL mit Menschen im Loop (Scurto et al., 2021)
- RL für sprachgesteuerte Viewpoint-Navigation (Zhao & Tao, 2025)
- Harte, reproduzierbare Metriken statt MLLM-Urteil (Ai et al., 2025b)

Fragestellung Lässt sich Transferfunktions-Design durch Sprache **und** eine exakte, kostenlose Metrik (statt eines MLLM-Richters) so weit automatisieren, dass daraus eine trainierbare RL-Baseline entsteht?



Die Transferfunktion: 24 Werte




$$\alpha(x) = \text{clip} \left(\sum_{i=1}^4 h_i \cdot \exp \left(-\frac{1}{2} \left(\frac{x - c_i}{w_i} \right)^2 \right), 0, 1 \right)$$

Design-Entscheidung

- c_i, w_i in echten **Hounsfield-Einheiten** (HU)
- nicht $[0, 255]$ wie bei den meisten TF-Editoren

Konsequenz

- Eine Gewebetabelle (Luft ... Kortikalis)
- Funktioniert unverändert auf synthetisch, CT **und** MRT (reskaliert)



Lokal, offline-first:

- Chat-Oberfläche (FastAPI + Vanilla JS)
- Text **und** Sprache (faster-whisper, lokal)
- Regel- **und** LLM-Parser (Ollama, lokal)
- Sofortiges Rendering nach jedem Kommando

Für RL-Daten von Anfang an gebaut:

- Jeder Schritt, jedes Bild, jede LLM-Anfrage wird geloggt
- 👍/👎-Feedback pro Antwort
- Verzweigbare Historie (zurück & neu verzweigen)

```
increase|decrease opacity for <klasse> [slightly|moderately|strongly]  
show only <klasse> [and <klasse> ...]  
<low|medium|high> opacity for <klasse> [, ... weitere Klassen]  
brighten|darken <klasse>      ·      reset
```


Testset

- 21 freie Formulierungen — Regelparser versteht sie **per Design** nicht
- z. B. *“make the skeleton pop”, “dim the soft tissue a little”*
- LLM bekommt dieselbe Synonymtabelle wie der Regelparser
- Vier Zielklassen: Skelett, Lunge, Weichgewebe, Gefäße


Parser	Korrekt
Regelbasiert	0 / 21
LLM (qwen2.5:7b)	20 / 21

Ergebnisse an echten CT-Daten

- Reale, de-identifizierte CT-Daten (3D Slicer Testdaten)
- Kein zusätzlicher Code nötig — bereits in HU gearbeitet



“Startzustand” — Standard-TF



“show only bone” — ein Kommando

Drei Bugs — gefunden durch echtes Testen, nicht durch Unit-Tests:

Render-Crash

- Annahme: würfelförmiger Datensatz → Absturz bei echten CT ($512 \times 512 \times 139$)
- **Fix:** Dimensionen pro Achse statt einer Kantenlänge

Sättigungs-Bug

- “increase opacity strongly” → Maximum in **einem** Schritt, danach stiller No-Op
- **Fix:** Schrittweite proportional zur Restdistanz, nicht fixer Betrag

Spracherkennung

- Whisper verhält “spongy” reproduzierbar: “sponges”, “spudgy”, “spore G”
- 24 echte Sprachkommandos: 19 (79 %) scheitern am Parser, nicht am System

Der teuerste Fehler war kein Bug

Eine Evaluation startete abends, der Fix an der Messung landete um 22:48, die Ergebnisdateien entstanden um 03:26 — mit dem Code vom Prozessesstart.

	veröffentlicht	korrekt gemessen
Policy, Median	+0.169	+0.275
Nachtrainieren hilft?	nein ($p = 0.85$)	ja ($p = 0.0064$)

Konsequenz Jede Ergebnisdatei speichert jetzt Git-Commit und Fingerabdruck der **importierten** Scoring-Module — erfasst beim Import, nicht beim Schreiben.

SAC, trainiert gegen **Sichtbarkeit pro Gewebeklasse** — ohne menschliche Daten.

Ziel 16 Werte: gewünschte Änderung von Sichtbarkeit und Helligkeit je Klasse

Zustand Ziel + HU-Histogramm + aktuelle Sichtbarkeit + erreichbare Obergrenze (57-dim)

Aktion Höhe, Breite und Farbe aller vier Peaks in **einem** Schritt (12-dim)

Reward attainment: welcher Anteil der geforderten Änderung erreicht wurde

Anmerkung Vier anatomische Klassen statt HU-Bänder. Organe und Muskeln teilen sich eine Klasse — keine Transferfunktion kann sie trennen.

Ergebnisse: 200 Instruktionen, sechs ungesehene Patienten

Verfahren	Evaluationen	Median	verbessert
Hill-Climbing (gründlich)	200	+0.730	100 %
Policy + 3 Verfeinerungen	4	+0.316	76 %
Policy allein	0	+0.275	73 %
Hill-Climbing (günstig)	10	+0.263	93 %
Nichts tun	0	0.000	—
Regelbasierter Executor	0	− 0.022	37 %
Zufall	0	− 0.040	39 %

Kernaussage Die Policy erreicht **ohne eine einzige Evaluation** das Niveau eines Hill-Climbers mit zehn — und schlägt jede nicht-suchende Baseline ($p < 0.001$, drei Seeds).

Anmerkung Ehrlich bleiben: die Suche ist weiterhin **zuverlässiger** (93 % vs. 73 % der Instruktionen verbessert). Das Argument für die Policy sind die Kosten pro Instruktion, nicht die Spitzenqualität.

Die Zielgröße ist selbst nur ein Stellvertreter

visibility.py misst, **wie viel** einer Klasse im Bild ankommt — nicht, ob ein Mensch das Bild für gelungen hält.

Erhebung Blindvergleich zweier Kandidaten zu derselben Instruktion, je sechs Ansichten

Tasten A · B · E (gleich) · S (überspringen)

Kontrolle Jedes zehnte Paar wiederholt ein früheres seitenvertauscht

Pilot 54 Urteile, als Pilot markiert und von jeder Auswertung ausgeschlossen

Erster Befund, noch ohne Aussagekraft Im Pilot stimmte die Metrik in **21 von 38** entschiedenen Paaren mit dem Urteil überein (55 %, 95 %-KI 0.40–0.70) — kaum über Zufall. Genau diese Lücke rechtfertigt ein gelerntes Reward-Modell.

Anmerkung Nach Instruktionsart: relative Änderungen 79 %, “show only” und zusammengesetzte Kommandos um 43 %.

Bradley-Terry-Modell auf den erhobenen Paarvergleichen; der Reward ersetzt die Metrik, nicht das Training (Scurto et al., 2021).

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N [y_i \log \sigma(R_\theta(z_i)) + (1 - y_i) \log(1 - \sigma(R_\theta(z_i)))]$$

- Stufe 1** Policy gegen attainment — ohne Menschen, beliebig viele Episoden
- Stufe 2** Feintuning gegen das Reward-Modell, verankert an Stufe 1 (KL-Strafe)
- Merkmale** rund 25 gemessene Werte je Kandidat statt Bild-Embeddings
- Messgröße** Blind-A/B zwischen Stufe 1 und Stufe 2, Gewinnrate mit KI

Warum die Verankerung nötig ist Ein gelerntes Reward-Modell gilt nur nahe seiner Daten. Hart optimiert gewinnt das Bild, das **das Modell** hoch bewertet — nicht das, was ein Mensch gut findet.

Vielen Dank für eure Aufmerksamkeit!

Fragen?

- Ai, K., Miao, H., Li, Z., Wang, C., & Liu, S. (2025b). An Evaluation-Centric Paradigm for Scientific Visualization Agents. *Arxiv Preprint Arxiv:2509.15160*.
- Ai, K., Tang, K., & Wang, C. (2025a). NLI4VolVis: Natural Language Interaction for Volume Visualization via LLM Multi-Agents and Editable 3D Gaussian Splatting. *Arxiv Preprint Arxiv:2507.12621*.
- Engel, D., Sick, L., & Ropinski, T. (2024). Leveraging Self-Supervised Vision Transformers for Segmentation-based Transfer Function Design. *IEEE Transactions on Visualization and Computer Graphics*. <https://doi.org/10.1109/TVCG.2024.3401755>
- Jeong, S., Li, J., Johnson, C., Liu, S., & Berger, M. (2024). Text-based transfer function design for semantic volume rendering. *Arxiv Preprint Arxiv:2406.15634*.
- Neuhäuser, C., & Westermann, R. (2023). Transfer Function Optimization for Comparative Volume Rendering. *Computer Graphics Forum*, 42(7).
- Scurto, H., Van Kerrebroeck, B., Caramiaux, B., & Bevilacqua, F. (2021). Designing Deep Reinforcement Learning for Human Parameter Exploration. *ACM Transactions on Computer-Human Interaction*, 28(1), 1–35.
- Wang, Y., Pan, B., Wang, K., Liu, H., Mao, J., Liu, Y., Zhu, M., Huang, X., Chen, W., Zhang, B., & Chen, W. (2025). IntuiTF: MLLM-Guided Transfer Function Optimization for Direct Volume Rendering. *Arxiv Preprint Arxiv:2506.18407*.
- Zhao, X., & Tao, J. (2025). Natural Language-Driven Viewpoint Navigation for Volume Exploration via Semantic Block Representation. *Arxiv Preprint Arxiv:2508.06823*.